# תוכן עניינים-


1. יצירת טבלת משתנים- _____ עמ 3
2. הסבר משתנים-_____ עמ 4
3. תיאור קשרים בין משתנים-_____ עמ 5
4. ניתוח תיאורי של המשתנים-_____ עמ 8
5. הוצאת חריגים-_____ עמ 10
6. פונקציית צפיפות והסתברות מצטברת-_____ עמ 13
7. גרף פיזור-_____ עמ 14
8. ייצוג קשרים באמצעות תרשימים-_____ עמ 15
9. טבלת שכיחויות-_____ עמ 16
10. נספח א- תרשימי חריגים (מוגדל)-_____ עמ 19
11. נספח ב- תרשים פיזור (מוגדל)-_____ עמ 23

## תקציר מנהלים –

מטרת הפרויקט הינה בניית מודל סטטיסטי אמין ומדויק לחיזוי פופולריות שירים. לאורך כל שלבי העבודה, השילוב בין הניתוח הטכני להבנה המוזיקלית הנחה את קבלת ההחלטות שלנו. השאיפה הייתה לא רק לקבל מדדי התאמה יבשים, אלא לייצר מודל שישקף נאמנה את המציאות ויספק הסבר הגיוני לקשרים המורכבים שבין מאפייני השמע לבין הצלחת השיר בקרב הקהל הרחב.

ניגשנו לעיבוד הנתונים מתוך הבנה כי המשתנים הגולמיים אינם מספיקים לתיאור מלא של הפופולריות. תחילה, סיננו משתנים שאינם בעלי תרומה סטטיסטית, כגון שמות השירים, והתמקדנו בטיוב המשתנים המסבירים. מהלך מרכזי שביצענו היה המרת משתנים רציפים לקטגוריאליים, ובראשם משתנה הקצב (Tempo). ההנחה הייתה שהשפעת הקצב אינה ליניארית, אלא מתחלקת לקבוצות מובחנות – איטי, בינוני ומהיר. מהלך זה, יחד עם יצירת משתני הדמה הנגזרים ממנו, אפשר למודל לזהות דפוסים ייחודיים לכל קבוצת קצב. בנוסף, יצרנו משתני אינטראקציה חדשים המבוססים על היגיון מוזיקלי, כשהבולט שבהם הוא השילוב בין אנרגיה (Energy) לרמת ההתאמה של השיר לריקוד (Danceability). מצאנו כי האפקט הסינרגטי של שני המשתנים יחד תורם לניבוי הפופולריות בצורה חזקה יותר מאשר כל אחד מהם בנפרד.

לאחר בניית מודל הבסיס באמצעות אלגוריתם בחירת משתנים (Forward ו Backward), ביצענו אבחון קפדני לבדיקת עמידה בהנחות הרגרסיה הקלאסיות. הבדיקות הוויזואליות והפורמליות חשפו כי המודל הליניארי הפשוט מתקשה להתמודד עם מורכבות הנתונים. זיהינו כי שונות השגיאות לא קבועה במודל וכי התפלגות השאריות חורגת מהנורמליות הצפויה. ממצאים אלו חיזקו את ההבנה כי הקשרים בין מאפייני האודיו לפופולריות אינם קווים ישרים פשוטים, והובילו אותנו לשלב הכרחי של שיפור המודל באמצעות כלים מתקדמים.

בשלב הסופי והמכריע, יישמנו סדרת טרנספורמציות מתמטיות כדי לגשר על הפערים שאובחנו. תחילה, בחנו את המשתנה המוסבר באמצעות מבחן Box-Cox, אך לאור התוצאות שהתקבלו (ערך למדא הקרוב ל-1), קיבלנו החלטה אסטרטגית לשמור על סקאלת הפופולריות המקורית לטובת בהירות הפרשנות. את עיקר המאמץ השקענו בתיקון המשתנים המסבירים: עבור משתנה האנרגיה ( Energy), הוספנו איברים פולינומים מדרגה שנייה ושלישית, אשר הצליחו לתפוס את הקשר הגלי והמורכב מול הפופולריות. במקביל, טיפלנו בהתפלגות הקיצונית של משתנה האינסטרומנטליות ( Instrumentalness) באמצעות טרנספורמציה לוגריתמית. פעולות אלו הוכיחו את עצמן כיעילות ביותר, כאשר המודל הסופי הציג את ערך ה-AIC הנמוך ביותר בתהליך (168,538.3) וכלל אך ורק משתנים מובהקים סטטיסטית, המציגים תמונה אמינה של הגורמים המשפיעים על הצלחת שיר.

### משוואת החיזוי במודל הסופי –

## טבלת משתנים-

| סוג המשתנה-מוסבר/מסביר | סימון בR | יחידת מידה | סוג המשתנה-רציף / קטגוריאלי |
|---|---|---|---|
| מסביר | Song_name | טקסט | קטגוריאלי |
| מוסבר | Song_popularity | מספר שלם | רציף |
| מסביר | Song_duration_ms | מילי שניות | רציף |
| מסביר | Acousticness | אחוז | רציף |
| מסביר | Dancebility | אחוז | רציף |
| מסביר | Energy | אחוז | רציף |
| מסביר | Instrumentalness | אחוז | רציף |
| מסביר | Liveness | אחוז | רציף |
| מסביר | Audio_mode | בינארי (1/0) | קטגוריאלי |
| מסביר | Speechiness | אחוז | רציף |
| מסביר | Tempo | ביטים לדקה | רציף |
| מסביר | Time_signature | ביטים לתיבת מוזיקלית | רציף |
| מסביר | Audio_valence | אחוז | רציף |

2. עיבוד מקדים:

## 2.1 הסרה של משתנים:

בשלב הראשון, בחנו את תרומתו השולית של כל משתנה מסביר בנפרד. מאחר וערכי ה-$R^2$ Adjustedשהתקבלו היו נמוכים מאוד עבור כלל המשתנים, בדיקה זו לא סיפקה אינדיקציה מספקת לסינון ראשוני. יתרה מכך, עבור חלק מהמשתנים (כגון audio_mode ו-energy) התקבל ערך שלילי, מה שמעיד כי תרומתם היחידנית להסברת השונות נמוכה מהקנס הסטטיסטי על הוספתם למודל. אי לכך, עברנו לגישת Backward Selection על בסיס המודל המלא (הכולל את כל המשתנים), כאשר הקריטריון המוביל הוא מקסום מדד ה-$R^2$ Adjusted. בתהליך זה נמצא כי הסרת המשתנה audio_mode (משתנה בינארי המבחין בין סולם מז'ורי למינורי) הובילה לשיפור במודל ולעלייה בערך ה-$R^2$ Adjusted, ולכן הוחלט להסירו. בדיקה חוזרת שבוצעה על המודל המעודכן (ללא המשתנה שהוסר) העלתה כי כל הסרה נוספת של משתנה פוגעת בטיב המודל. לפיכך, תהליך הסינון נעצר בשלב זה.

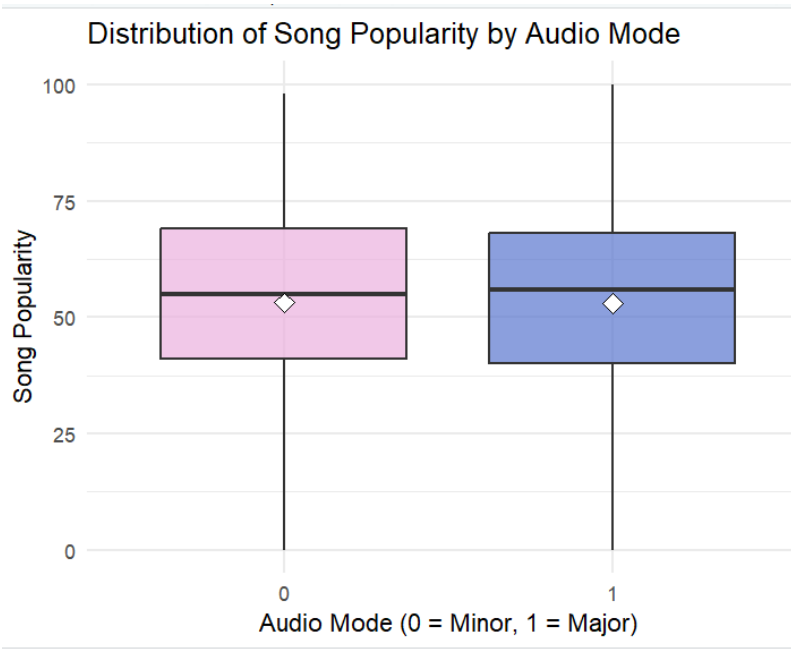
```
--- Table 1: Univariate Analysis Results ---

> print(results_uni_sorted)
          Predictor   Adj_R2
1            energy -0.00005
2        audio_mode -0.00003
3  song_duration_ms  0.00030
4       speechiness  0.00041
5             tempo  0.00046
6    time_signature  0.00117
7          liveness  0.00146
8     audio_valence  0.00274
9      acousticness  0.00420
10     danceability  0.01082
11 instrumentalness  0.01708
```

```
--- Table 2: Backward Selection Results ---

> print(results_loo_sorted)
   Removed_Variable Adj_R2_Without Impact_Delta
1        audio_mode        0.04036     0.000025
2             tempo        0.04026    -0.000076
3       speechiness        0.04021    -0.000127
4    time_signature        0.04009    -0.000245
5            energy        0.04008    -0.000258
6  song_duration_ms        0.03999    -0.000346
7          liveness        0.03951    -0.000833
8      acousticness        0.03869    -0.001647
9      danceability        0.03146    -0.008882
10    audio_valence        0.03068    -0.009659
11 instrumentalness        0.02375    -0.016590
>
```

התרשים מחזק החלטה זו וממחיש כי אין הבדל ויזואלי ניכר בהתפלגות הפופולריות בין שני המצבים של המשתנה. ניתן לראות בתרשים כי המדדים המרכזיים זהים כמעט לחלוטין בשתי הקבוצות: הקו השחור החוצה את הקופסאות (החציון) והנקודה הלבנה (הממוצע) נמצאים באותו גובה בדיוק. חפיפה מלאה זו בין הקופסאות מאששת את המסקנה הסטטיסטית, ומעידה כי לסולם המוזיקלי אין השפעה ממשית על הצלחת השיר.



2.2 <u>התאמת משתנים:</u>

- הגדרת המשתנה Tempo כמשתנה קטגוריאלי –

לצורך בחינת התאמת המשתנה Tempo למודל, נבחנה האפשרות לייצגו כמשתנה קטגוריאלי, מתוך ההנחה כי הקשר בין קצב השיר לפופולריות אינו בהכרח לינארי וכי חלוקה לרמות קצב עשויה לשקף טוב יותר את השפעתו על העדפות המאזינים. בהתאם לכך, הוגדר המשתנה באמצעות חלוקה לשלוש קטגוריות: Slow, Medium ו-Fast. לשם בחינת התאמה זו, הותאמו שני מודלים - מודל ייחוס ללא התאמות ומודל חלופי הכולל את המשתנה הקטגוריאלי והושוו באמצעות מדדי Adjusted $R^2$ ו-AIC. השוואת המודלים הצביעה על שיפור במדדי ההתאמה במודל הכולל את ההתאמה, המעיד על ייצוג יעיל יותר של השפעת הקצב תוך איזון משופר בין איכות ההתאמה למורכבות המודל.
לפיכך, הוחלט לאמץ התאמה זו ולהכליל את המשתנה הקטגוריאלי Tempo_cat במודל להמשך הניתוח.

```
--- TEMPO Representation Comparison ---
> cat("Continuous tempo:  Adj R² =", round(adj_cont, 5), "| AIC =", round(aic_cont, 2), "\n")
Continuous tempo:  Adj R² = 0.04032 | AIC = 168945.1
> cat("Categorical tempo: Adj R² =", round(adj_cat, 5),  "| AIC =", round(aic_cat, 2), "\n")
Categorical tempo: Adj R² = 0.04189 | AIC = 168915.3
>
```

הגדרת המשתנה song_duration_ms כמשתנה קטגוריאלי –

על מנת לדייק את אופן השפעת אורך השיר על הפופולריות, נבחנה ההשערה כי הקשר אינו לינארי פשוט (כלומר, לא בהכרח "ככל שהשיר ארוך יותר הוא מצליח יותר"), אלא קיים טווח זמן אופטימלי. בהתאם לכך, בוצעה דיסקרטיזציה של המשתנה לשלוש קטגוריות (Short, Medium, Long) תוך חלוקת הנתונים לקבוצות שוות-גודל (על בסיס אחוזונים).
השוואה מול המודל הרציף הציגה עליונות למודל הקטגוריאלי: נרשמה ירידה במדד ה AIC ועלייה ב Adjusted $R^2$.
לפיכך, הוחלט לאמץ התאמה זו ולהכליל את המשתנה הקטגוריאלי length_cat במודל להמשך הניתוח.

```
--- DURATION Representation Comparison ---
> cat("Continuous duration:  Adj R² =", round(adj_len_cont, 5),
+     "| AIC =", round(aic_len_cont, 2), "\n")
Continuous duration:  Adj R² = 0.04189 | AIC = 168915.3
> cat("Categorical duration: Adj R² =", round(adj_len_cat, 5),
+     "| AIC =", round(aic_len_cat, 2), "\n")
Categorical duration: Adj R² = 0.04247 | AIC = 168904.8
>
```

- בחינת סכום לינארי של audio valence ו-energy

במסגרת הניסיון לטיוב המודל, נבחנה האפשרות להגדיר משתנה חדש המבוסס על סכום שני המשתנים הרגשיים: audio_valence ו-energy. ההנחה הייתה כי שילוב בין המטען הרגשי של השיר לבין רמת האנרגטיות שלו עשוי לייצג בצורה הוליסטית יותר את חוויית ההאזנה ובכך לשפר את ניבוי הפופולריות.
לצורך הבדיקה, הותאם מודל הכולל את משתנה הסכום המאוחד, והושווה אל מול מודל הבסיס (בו המשתנים מופיעים בנפרד). תוצאות ההשוואה העלו כי האיחוד הוביל לירידה באיכות המודל: נצפתה ירידה בערך ה-Adjusted $R^2$ ועלייה במדד ה-AIC.
הממצאים מעידים כי כל אחד מהמשתנים תורם אינפורמציה ייחודית ונפרדת למודל. אי לכך, הוחלט שלא לאמץ התאמה זו ולהותיר את המשתנים בנפרד.

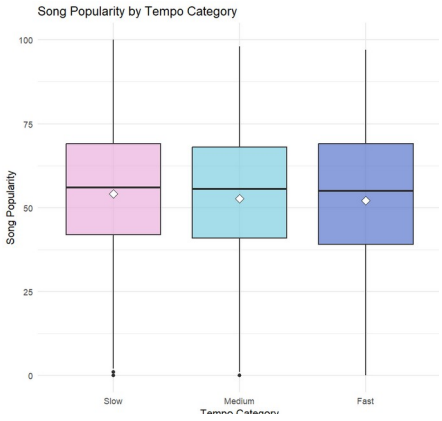
```
--- Valence + Energy Sum Comparison ---
> cat("Base (energy + valence): Adj R² =", round(adj_base, 5),
+     "| AIC =", round(aic_base, 2), "\n")
Base (energy + valence): Adj R² = 0.04247 | AIC = 168904.8
> cat("Sum (val_energy_sum):    Adj R² =", round(adj_sum, 5),
+     "| AIC =", round(aic_sum, 2), "\n")
Sum (val_energy_sum):    Adj R² = 0.04127 | AIC = 168927.5
>
```

2.3 הגדרת משתנה דמה –

המשתנה Tempo_cat הוא משתנה קטגוריאלי, המתאר את קצב השיר בחלוקה {Slow, Medium Fast}.

לצורך שילובו במודל רגרסיה לינארית, נדרש להגדיר עבורו משתני דמה, כאשר אחת הקטגוריות נבחרת כקטגוריית ייחוס. קטגוריית ה Slow נבחרה כקטגוריית הייחוס. בהתאם לכך, ובהינתן כי למשתנה שלוש קטגוריות שונות, הוגדרו שני משתני דמה עבור הערכים Medium ו Fast - כל משתנה דמה מקבל ערך 1 אם השיר משתייך לקטגוריית הקצב המתאימה ו-0 אחרת, בעוד ששירים מקטגוריית ה Slow מקבלים ערך 0 בשני משתני הדמה. הגדרה זו מאפשרת אמידה תקינה של המודל, כאשר מקדמי משתני הדמה מייצגים את ההבדל הצפוי בפופולריות השיר ביחס לשירים מקטגוריית ה Slow בהינתן ששאר המשתנים במודל קבועים.

התרשים מציג את ההבדלים במדדי המרכז (חציון וממוצע) בין שלוש קטגוריות הקצב. ניתן לראות כי קיימת שונות בהתפלגות הפופולריות בין הקבוצות (הקופסאות אינן באותו גובה), ממצא המצדיק את השימוש במשתני דמה לצורך אמידת ההשפעה הייחודית של כל קטגוריה ביחס לקטגוריית הבסיס.




2.4 הגדרת משתני אינטרקציה –

- בחינת אינטראקציה בין energy ל - danceability

נבדקה אינטראקציה בין המשתנים energy ו-danceability, מתוך ההשערה כי השפעת רמת האנרגטיות של השיר על רמת הפופולריות שלו עשויה להשתנות בהתאם למידת ההתאמה שלו לריקוד. מבחינה מוזיקלית, ניתן לצפות כי אנרגיה גבוהה תתרום יותר

לפופולריות כאשר השיר גם מתאים לריקוד, בעוד שבשירים שאינם ריקודיים תרומה זו עשויה להיות חלשה יותר. עם זאת, מאחר שהמשתנים energy ו-danceability מתארים מאפיינים קרובים יחסית של אופי השיר, ייתכן היה שכל אחד מהם משפיע על פופולריות השיר באופן עצמאי, כך שההשפעה של האנרגטיות אינה משתנה בהתאם לרמת הריקודיות, אלא מצטברת להשפעתה בצורה פשוטה ולינארית, ללא תלות הדדית בין המשתנים.
השוואת מודל ללא אינטראקציה למודל הכולל איבר אינטראקציה הראתה שיפור במדדי ההתאמה, המתבטא בעלייה במדד Adjusted $R^2$ ובירידה במדד AIC. בנוסף, מקדם האינטראקציה נמצא מובהק סטטיסטית, ומבחן ANOVA בין המודלים המקוננים הצביע על ירידה מובהקת ב־Residual Sum of Squares, עם ערך F גבוה ו־p-value קטן מאוד.
ממצאים אלו מעידים כי השפעת האנרגטיות על פופולריות השיר אכן תלויה במידת הריקודיות, ולכן האינטראקציה danceability × energy אומצה במודל.

```
--- Interaction: danceability * energy ---
> cat("Base model:       Adj R² =", round(adj_base, 5),
+     "| AIC =", round(aic_base, 2), "\n")
Base model:       Adj R² = 0.04247 | AIC = 168904.8
> cat("With interaction: Adj R² =", round(adj_int, 5),
+     "| AIC =", round(aic_int, 2), "\n")
With interaction: Adj R² = 0.04722 | AIC = 168812.1
>
> # 5) מבחן ANOVA בין המודלים (nested)
> anova_result <- anova(m_base, m_int)
> anova_result
Analysis of Variance Table

Model 1: song_popularity ~ danceability + energy + audio_valence + speechiness +
    acousticness + instrumentalness + liveness + length_cat +
    tempo_cat + time_signature
Model 2: song_popularity ~ danceability * energy + audio_valence + speechiness +
    acousticness + instrumentalness + liveness + length_cat +
    tempo_cat + time_signature
  Res.Df     RSS Df Sum of Sq      F    Pr(>F)
1  18820 8645585
2  18819 8602227  1     43358 94.854 < 2.2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
>
```

- בחינת אינטרקציה בין energy ל audio_valence

נבדקה אינטראקציה בין המשתנים energy ו-audio_valence, מתוך ההשערה כי השפעת רמת האנרגטיות של השיר על פופולריותו עשויה להשתנות בהתאם לאופי הרגשי שהוא משדר. באופן אינטואיטיבי, שיר אנרגטי בעל רמת חיוביות גבוהה עשוי להיתפס כמלהיב, נגיש ומהנה יותר לקהל הרחב, בעוד ששיר אנרגטי בעל רמת חיוביות נמוכה עשוי לעורר תחושה מתוחה או אגרסיבית, ולכן להשפיע אחרת על הפופולריות. עם זאת, מאחר שהמשתנים energy ו-audio_valence מתארים היבטים שונים של השיר - האחד את רמת העוצמה והקצב, והשני את הטון הרגשי, ייתכן היה שכל אחד מהם משפיע על פופולריות השיר באופן עצמאי, כך שהשפעת האנרגטיות אינה משתנה לפי רמת החיוביות של השיר, אלא מצטברת להשפעתו בצורה פשוטה ולינארית, ללא תלות הדדית בין המשתנים.
השוואת מודל ללא אינטראקציה למודל הכולל איבר אינטראקציה הראתה שיפור במדדי ההתאמה, המתבטא בעלייה במדד Adjusted $R^2$ ובירידה במדד AIC. בנוסף, מקדם האינטראקציה נמצא מובהק סטטיסטית, ומבחן ANOVA בין המודלים המקוננים הצביע על ירידה מובהקת ב־Residual Sum of Squares, עם ערך F גבוה ו־p-value קטן מאוד.
ממצאים אלו מעידים כי השפעת האנרגטיות על פופולריות השיר תלויה גם ברמת החיוביות שלו, ולכן האינטראקציה energy × audio_valence אומצה במודל.

```
--- Interaction 2: energy * audio_valence ---
> cat("Model from Step 1:  Adj R² =", round(adj_step1, 5),
+     "| AIC =", round(aic_step1, 2), "\n")
Model from Step 1:  Adj R² = 0.04722 | AIC = 168812.1
> cat("Model with Int 2:   Adj R² =", round(adj_int2, 5),
+     "| AIC =", round(aic_int2, 2), "\n")
Model with Int 2:   Adj R² = 0.0481 | AIC = 168795.8
>
> anova_2 <- anova(m_step1, m_int_2)
> print(anova_2)
Analysis of Variance Table

Model 1: song_popularity ~ danceability * energy + audio_valence + speechiness +
    acousticness + instrumentalness + liveness + length_cat +
    tempo_cat + time_signature
Model 2: song_popularity ~ danceability * energy + energy * audio_valence +
    speechiness + acousticness + instrumentalness + liveness +
    length_cat + tempo_cat + time_signature
  Res.Df     RSS Df Sum of Sq      F    Pr(>F)
1  18819 8602227
2  18818 8593861  1    8366.1 18.319 1.877e-05 ***
```

- אינטראקציה בין acousticness ל-instrumentalness

נבדקה אינטראקציה בין המשתנים acousticness ו-instrumentalness, מתוך ההשערה כי השפעת האופי האקוסטי של השיר על רמת הפופולריות שלו עשויה להיות תלויה במידת היותו אינסטרומנטלי. שירים אקוסטיים הכוללים שירה עשויים להיתפס כנגישים ומזוהים יותר על ידי הקהל הרחב, בעוד ששירים אקוסטיים אינסטרומנטליים עשויים לפנות לקהל מצומצם יותר, כך שהשפעת האקוסטיות אינה אחידה בכל רמות האינסטרומנטליות. מנגד, מאחר ששני המשתנים מתארים מאפיינים שונים אך קרובים של מבנה השיר, ייתכן היה שכל אחד מהם ישפיע על הפופולריות באופן עצמאי, ללא תלות הדדית ביניהם.
השוואת מודל ללא אינטראקציה למודל הכולל איבר אינטראקציה הצביעה על שיפור משמעותי במדדי ההתאמה, עם עלייה ניכרת במדד Adjusted $R^2$ וירידה חדה במדד AIC. בנוסף, מבחן ANOVA בין המודלים המקוננים הצביע על ירידה מובהקת ב־Residual Sum of Squares, עם ערך F גבוה במיוחד ו־p-value קטן מאוד, המעידים על תרומה מובהקת של האינטראקציה להסברת השונות במשתנה המוסבר. ממצאים אלו מחזקים את ההשערה כי השפעת האקוסטיות על פופולריות השיר תלויה במידת היותו אינסטרומנטלי, ולכן האינטראקציה instrumentalness × acousticness אומצה במודל.

```
--- Interaction 3: acousticness * instrumentalness ---
> cat("Model from Step 2:  Adj R² =", round(adj_step2, 5), "| AIC =", round(aic_step2, 2),
"\n")
Model from Step 2:  Adj R² = 0.0481 | AIC = 168795.8
> cat("Model with Int 3:   Adj R² =", round(adj_int3, 5), "| AIC =", round(aic_int3, 2),
"\n")
Model with Int 3:   Adj R² = 0.05474 | AIC = 168665
>
> # 4) מבחן ANOVA
> anova_3 <- anova(m_step2, m_int_3)
> print(anova_3)
Analysis of Variance Table

Model 1: song_popularity ~ danceability * energy + energy * audio_valence +
    speechiness + acousticness + instrumentalness + liveness +
    length_cat + tempo_cat + time_signature
Model 2: song_popularity ~ danceability * energy + energy * audio_valence +
    acousticness * instrumentalness + speechiness + liveness +
    length_cat + tempo_cat + time_signature
  Res.Df     RSS Df Sum of Sq      F    Pr(>F)
1  18818 8593861
2  18817 8533441  1     60419 133.23 < 2.2e-16 ***
```

הסופי ומדדיו

הצגת המודל

```
                Median      3Q     Max
                 2.919  15.484  45.886

                            Estimate Std. Error t value Pr(>|t|)
–                            60.1186     2.8396  21.171  < 2e-16 ***
                              0.7859     3.3465   0.235 0.814328
                            -21.9689     2.9489  -7.450 9.75e-14 ***
                             -4.1434     1.5927  -2.601 0.009290 **
                             -7.8028     0.7913  -9.861  < 2e-16 ***
                            -22.3648     1.0473 -21.355  < 2e-16 ***
                             -4.0243     1.1065  -3.637 0.000276 ***
                            -15.8205     2.3361  -6.772 1.31e-11 ***
                             -2.0649     0.3924  -5.263 1.43e-07 ***
                             -1.1122     0.3877  -2.868 0.004131 **
                              1.3723     0.3891   3.527 0.000422 ***
                              0.2840     0.3899   0.728 0.466476
                              1.3451     0.5374   2.503 0.012330 *
rgy                          27.2739     4.9390   5.522 3.39e-08 ***
ence                          8.7710     3.4285   2.558 0.010526 *
trumentalness                21.5732     1.8690  11.543  < 2e-16 ***

0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

d error: 21.3 on 18817 degrees of freedom
ed:  0.05549,   Adjusted R-squared:  0.05474
71 on 15 and 18817 DF,  p-value: < 2.2e-16
```

המודל הסופי מציג הסבר משופר ומובהק, המאשש כי למאפייני האודיו והמבנה של השירים יש השפעה ממשית על סיכויי הצלחתם. בניתוח המשתנים נמצא כי כל שלוש האינטראקציות שנבחנו – הקשר בין אנרגיה לריקודיות, בין אנרגיה לחיוביות ובין אקוסטיות לאינסטרומנטליות – נמצאו מובהקות סטטיסטית. ממצא זה מדגיש כי השפעת מאפיין מוזיקלי מסוים אינה פועלת בחלל ריק; כך למשל, רמת האנרגיה משפיעה על הפופולריות באופן שונה בהתאם למידת הריקודיות או הטון הרגשי של השיר.
בנוסף, ניתן לראות כי חלק מהמשתנים שהופיעו כבודדים (כמו הריקודיות או חלק מקטגוריות אורך השיר) אינם מובהקים במודל זה. הדבר אינו מעיד על חוסר חשיבותם, אלא על כך שתרומתם למודל מתבטאת בעיקר דרך איברי האינטראקציה ובשילוב עם משתנים אחרים. במקביל, המובהקות הגבוהה שקיבלו המשתנים הקטגוריאליים (כמו קצב השיר ואורכו) מוכיחה כי קיימים הבדלים מהותיים בהעדפות המאזינים כתלות במבנה הטכני של השיר. לסיכום, התוצאות משקפות כי המפתח להבנת הפופולריות טמון בסינרגיה שבין המאפיינים האקוסטיים השונים לבין המבנה הכולל של היצירה.

## 3. התאמת המודל ובדיקת הנחות המודל:

### 3.1 בחירת משתני המודל:

לצורך קביעת המבנה המיטבי של המודל, בוצעה השוואה בין שני אלגוריתמים לבחירת משתנים המבוססים על קריטריון ה-AIC: בחירה קדימה (Forward Selection) והסרה אחורה (Backward

Elimination). מניתוח התוצאות עולה כי שני האלגוריתמים לא הגיעו למודל זהה; בעוד שאלגוריתם ה-Forward הציג מודל מצומצם יותר, אלגוריתם ה-Backward שמר על המבנה המורכב הכולל את כל איברי האינטראקציה שהוגדרו בתחילה.

בחינת מדדי ההתאמה מעלה כי המודל שהתקבל בתהליך ה-Backward השיג ערך AIC נמוך, נתון המעיד על יכולת חיזוי גבוהה יותר. חוסר ההתאמה בין האלגוריתמים מלמד כי שיטת ה-Forward התקשתה לזהות את תרומתן של האינטראקציות, ככל הנראה מאחר והמשתנים המרכיבים אותן לא הציגו השפעה ישירה חזקה מספיק כשלעצמם. לעומת זאת, אלגוריתם ה-Backward איפשר כי השילובים בין המשתנים אכן תורמים משמעותית לכושר ההסבר של המודל.

לאור זאת, המודל שנבחר להמשך הניתוח הוא המודל שהתקבל בתהליך ה-Backward, המשלב בצורה המיטבית בין דיוק סטטיסטי למורכבות התיאורטית הנדרשת.

- תוצאות

- Forward Selection

```
Call:
lm(formula = song_popularity ~ instrumentalness + danceability +
    audio_valence + tempo_cat + acousticness + liveness + length_cat +
    speechiness + time_signature + instrumentalness:acousticness,
    data = df)

Residuals:
    Min      1Q  Median      3Q     Max
-63.143 -12.217   2.856  15.465  45.510
```

- Backward Selection

```
Call:
lm(formula = song_popularity ~ danceability + energy + speechiness +
    acousticness + instrumentalness + liveness + audio_valence +
    tempo_cat + length_cat + time_signature + energy:danceability +
    energy:audio_valence + acousticness:instrumentalness, data = df)

Residuals:
    Min      1Q  Median      3Q     Max
-63.342 -12.172   2.919  15.484  45.886
```

- השוואה בין המודלים בעזרת מדד AIC

```
> # Compare AIC values: Lower is better
> cat("AIC (Backward Model):", AIC(model_back), "\n")
AIC (Backward Model): 168665
> cat("AIC (Forward Model):", AIC(model_fwd), "\n")
AIC (Forward Model): 168719.3
>
```

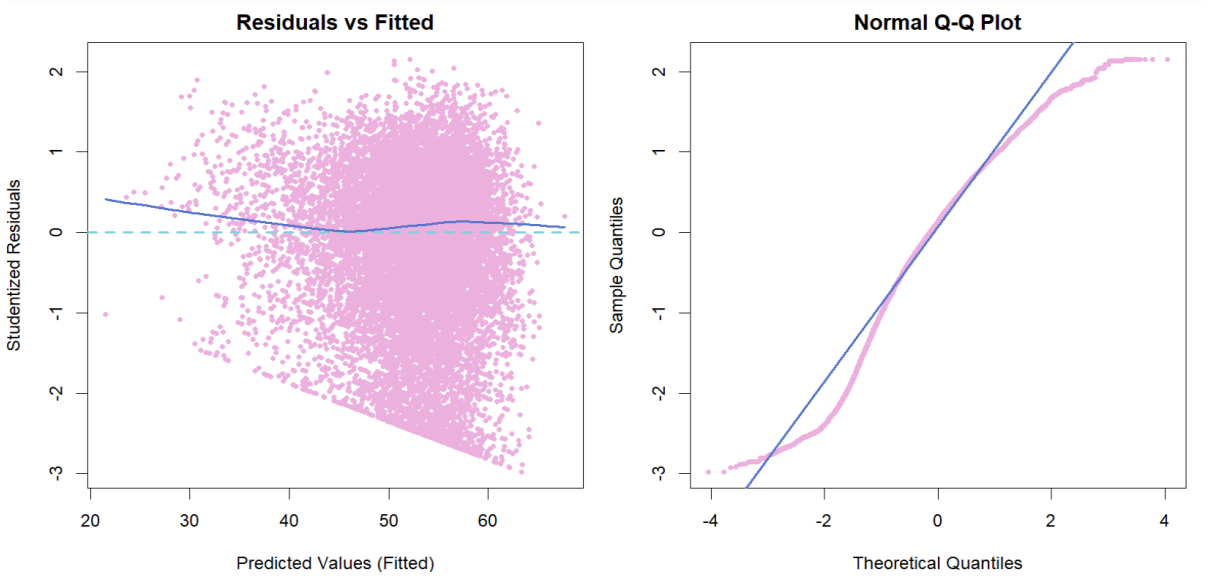
3.2 <u>בדיקת ויזואלית של הנחות המודל:</u>

לצורך בחינת תקפות המודל, הופקו תרשימי אבחון המבוססים על השאריות המנורמלות (Studentized Residuals):

**בחינת ליניאריות**: בחינה ויזואלית של גרף השאריות מול הערכים החזויים, ניתן לראות כי הנחת הליניאריות אינה מתקיימת במלואה. אמנם קו המגמה הכחול נמצא בקרבת קו האפס, אך פיזור הנקודות אינו אקראי ואחיד סביבו. העובדה שהשגיאות יוצרות תבנית ברורה מעידה על כך שהמודל הליניארי אינו מצליח לתפוס את מלוא המורכבות של הקשר בין המשתנים, וכי קיימת סטייה מהותית מהמבנה הליניארי המצופה.

**שוויון שונויות**: בבחינת פיזור הנקודות ניכרת צורה של "משפך". בחלק השמאלי של הגרף (ערכים חזויים נמוכים) הפיזור של השאריות מצומצם יחסית, אך ככל שמתקדמים ימינה לעבר ערכים חזויים גבוהים יותר, פיזור השאריות מתרחב משמעותית. תופעה זו מעידה על חוסר שוויון שונויות, המצביעה על כך ששונות השגיאות אינה קבועה והדיוק של המודל משתנה בטווחי הפופולריות השונים.

**בחינת נורמליות**: תרשים ה-QQ בוחן האם השגיאות מתפלגות נורמלית על ידי השוואת השאריות בפועל מול התפלגות תאורטית. ניתן להבחין כי בחלקו המרכזי של הגרף, הנקודות הוורודות עוקבות בדיוק רב אחרי הקו האלכסוני, מה שמעיד על התנהגות נורמלית במרכז ההתפלגות. עם זאת, בשני הקצוות (ה"זנבות"), הנקודות מתרחקות מהקו – בחלק התחתון הן צונחות מתחתיו ובחלק העליון הן מתיישרות ימינה. סטיות אלו מעידות על כך שהתפלגות השאריות כוללת ערכים קיצוניים רבים יותר מאשר בהתפלגות נורמלית תאורטית.



3.3 בדיקה פורמלית של הנחות המודל:

**הנחת הליניאריות:** לצורך בדיקת הנחת הליניאריות באופן פורמלי, בוצע מבחן Ramsey RESET. במבחן זה התקבל ערך P-Value נמוך משמעותית מרמת המובהקות המקובלת. לאור תוצאה זו, אנו דוחים את השערת האפס וקובעים כי הנחת הליניאריות אינה מתקיימת במלואה. ממצא זה מעיד על כך שהקשר בין המשתנים המנבאים לפופולריות אינו מודל ליניארי פשוט, כפי שציפינו מהניתוח הוויזואלי.

```
--- Ramsey RESET Test ---
> print(reset_results)

        RESET test

data:  model_back
RESET = 18.28, df1 = 2, df2 = 18815, p-value = 1.172e-08
```

**הנחת הנורמליות:** לצורך בדיקת הנחת הנורמליות באופן פורמלי, בוצע מבחן Kolmogorov-Smirnov (KS) המשווה את התפלגות השאריות המנורמלות להתפלגות נורמלית תאורטית. במבחן זה התקבל ערך P-Value נמוך משמעותית מרמת המובהקות המקובלת, ולפיכך אנו

דוחים את השערת האפס וקובעים כי שאריות המודל אינן מתפלגות באופן נורמלי. תוצאה זו מאששת באופן סטטיסטי את הסטייה שנצפתה ב"זנבות" של גרף ה-QQ בבדיקה הוויזואלית.

```
        Asymptotic one-sample Kolmogorov-Smirnov test

data:  jitter(res_student)
D = 0.05837, p-value < 2.2e-16
alternative hypothesis: two-sided

> cat("\n--- Ramsey RESET Test ---\n")
```

4. <u>שיפור המודל:</u>

במטרה למקסם את דיוק המודל ואת מדד ה-AIC, ביצענו תהליך אופטימיזציה ממוקד שכלל שלושה שלבים עיקריים:

<u>שלילת טרנספורמציה על המשתנה המוסבר:</u> תחילה ביצענו מבחן Box-Cox לאיתור עיוותים בהתפלגות הפופולריות. התקבלה תוצאה של lambda=1.19, מכיוון שערך זה קרוב ל-1, הוחלט לשמור על המשתנה המוסבר (Y) בסקלה המקורית כדי לשמר את יכולת הפרשנות של המודל, ולהתמקד בשיפור המשתנים המסבירים.

<u>טיפול באי-ליניאריות במשתנים המסבירים:</u> לאור אבחון מקדים שביצענו, הוספנו למודל איברים פולינומים

למשתנה האנרגיה ( ) המייצגים קשר לא-ליניארי מובהק. כמו כן, זיהינו כי משתנה האינסטרומנטליות מתפלג בצורה קיצונית, ולכן החלנו עליו טרנספורמציה לוגריתמית ((log(Instrumentalness + 0.001). שינוי זה שיפר דרמטית את רגישות המודל לערכים נמוכים (t-value = -22.43).

<u>ניפוי סופי (Stepwise):</u> לסיום, הרצנו אלגוריתם Stepwise (דו-כיווני) על המודל המורחב. האלגוריתם ניפה משתנים וטרנספורמציות שלא תרמו לכושר ההסבר.

<u>תוצאות:</u> המודל הסופי מציג ערך AIC של 168,538.3 וערך $R^2$ של כ-0.062 (שיפור של כ-20% ביחס למודל הבסיס).

כל המשתנים שנבחרו במודל הסופי הינם מובהקים סטטיסטית ברמת מובהקות של 5%.

המודל הסופי:

```
Coefficients:
                               Estimate Std. Error t value Pr(>|t|)
(Intercept)                   4.734e+01  2.966e+00  15.960  < 2e-16 ***
song_duration_ms             -1.644e-05  4.051e-06  -4.060 4.93e-05 ***
acousticness                 -3.988e+00  7.707e-01  -5.174 2.32e-07 ***
danceability                  1.623e+01  1.212e+00  13.392  < 2e-16 ***
energy                       -1.008e+02  9.186e+00 -10.969  < 2e-16 ***
liveness                     -3.783e+00  1.104e+00  -3.428 0.000609 ***
speechiness                  -6.693e+00  1.592e+00  -4.204 2.64e-05 ***
tempo                         6.084e-02  1.258e-02   4.836 1.33e-06 ***
time_signature                1.184e+00  5.349e-01   2.213 0.026876 *
audio_valence                -1.133e+01  7.384e-01 -15.346  < 2e-16 ***
tempo_catMedium              -3.584e+00  5.344e-01  -6.707 2.05e-11 ***
tempo_catFast                -5.003e+00  8.715e-01  -5.741 9.56e-09 ***
length_catMedium              2.139e+00  4.262e-01   5.018 5.27e-07 ***
length_catLong                2.334e+00  5.899e-01   3.957 7.62e-05 ***
I(energy^2)                   2.099e+02  1.803e+01  11.642  < 2e-16 ***
I(energy^3)                  -1.284e+02  1.089e+01 -11.794  < 2e-16 ***
log(instrumentalness + 0.001) -1.717e+00  7.655e-02 -22.431  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 21.22 on 18816 degrees of freedom
Multiple R-squared:  0.06193,   Adjusted R-squared:  0.06113
F-statistic: 77.63 on 16 and 18816 DF,  p-value: < 2.2e-16

>
```

```
> AIC(model_final_best)
[1] 168538.3
```